Introduction à l'apprentissage profond

Filière Geo Data Science : UE2 Analyse de Données

Juste Raimbault[1] (d'après les slides de L. Landrieu)

2024-2025

[1]LaSTIG, IGN-ENSG-UGE

ENSG Géomatique
ÉCOLE NATIONALE DES SCIENCES GÉOGRAPHIQUES

Introduction à l'apprentissage profond

Introduction

Réseaux de Neurones Artificiels

Entraînement

Implémentation

Données raster

Histoire des réseaux de neurones

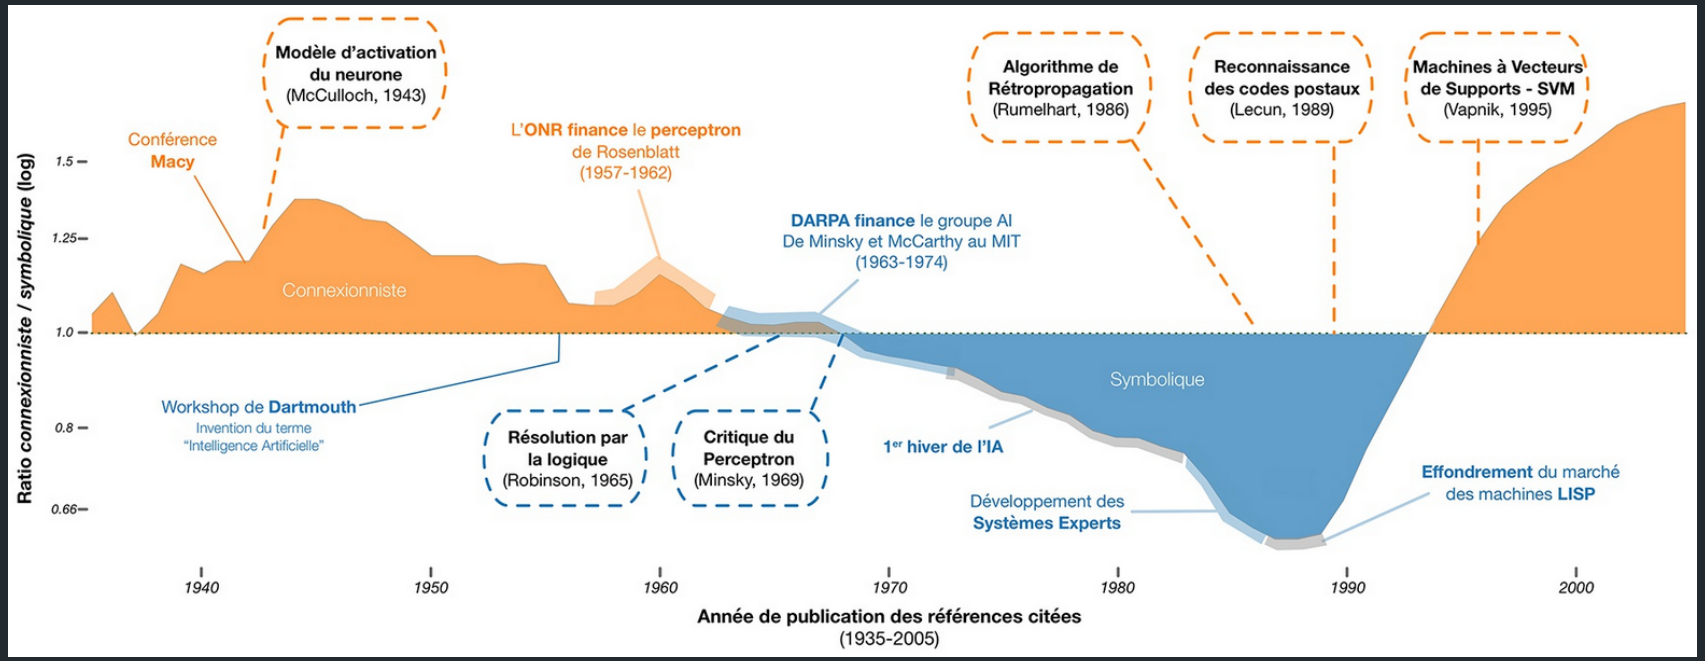

[Cardon et al., 2018]

Apprentissage profond

- **Apprentissage profond :** une sous-classe de méthodes en apprentissage machine, basée sur des réseaux de neurones
- **Construction endogène** des descripteurs, contrairement au ML classique (ex. SIFT en analyse d'image)
- Relativement simple théoriquement, succès grâce à la quantité de données et à la puissance de calcul (implémentations GPU)
- Pertinent et efficace pour : perception (image, vidéo, son, texte, 3D), données relationnelles (graphe), analyse sémantique, génération
- Non pertinent pour : optimisation (inverse, convexe), problèmes avec algorithme exact, environnements critiques, données tabulaires, géométrie, combinatoire

Introduction

Réseaux de Neurones Artificiels

Entraînement

Implémentation

Données raster

Neurone artificiel

Transforme des input x_i en une output y par une combinaison linéaire (w_i poids et b biais) et une fonction f non linéaire

$$y = f\left(\sum_i w_i x_i + b\right)$$

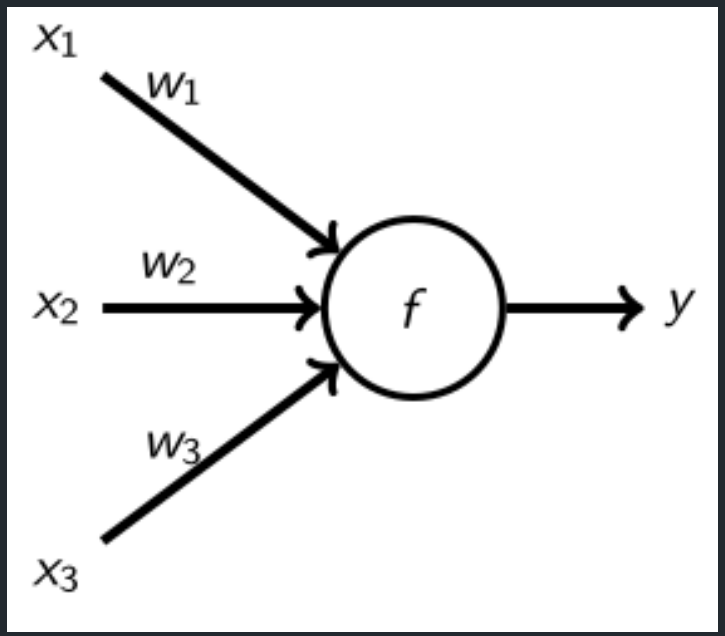

Fonctions d'activation

Rectified Linear Unit : $f = ReLu(x) = max(0, x)$

Softmax : transforme en distribution de probabilité

$$f(\vec{x}) = (\exp(x_i)/sum_j \exp(x_j))_i$$

Sigmoide : lissage:

$$f(x) = \frac{1}{1 + \exp(-x)}$$

Réseaux de Neurones Artificiels

Combinaison des neurones en réseau :

- **Largeur** : neurones dans une couche ; **Profondeur** : nombre de couches
- Réseaux intermédiaires : “maps” capturant des descripteurs de l’entrée

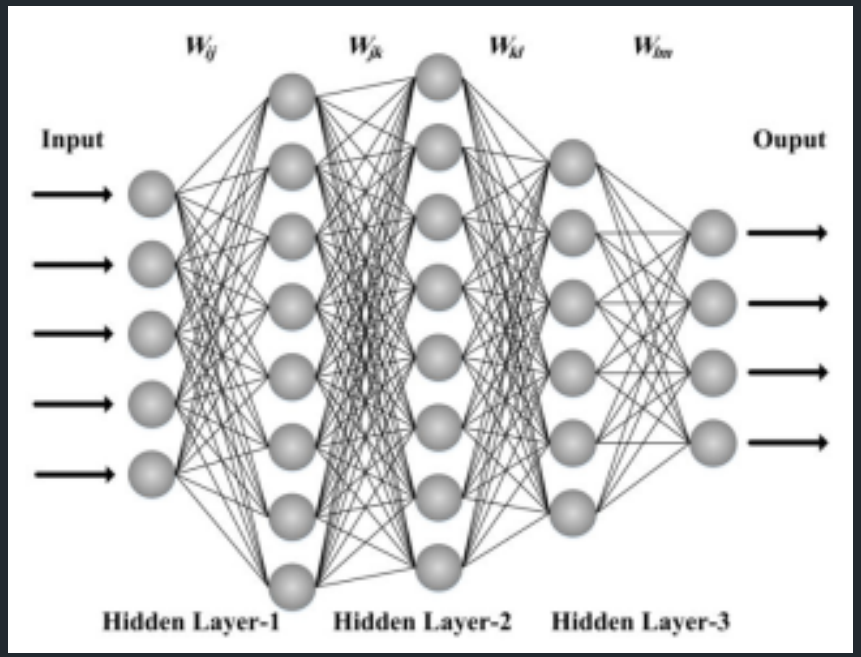

Couche linéaire

Produit matriciel $F(X) = WX + B$

$\rightarrow$ brique élémentaire d'architectures plus compliquées

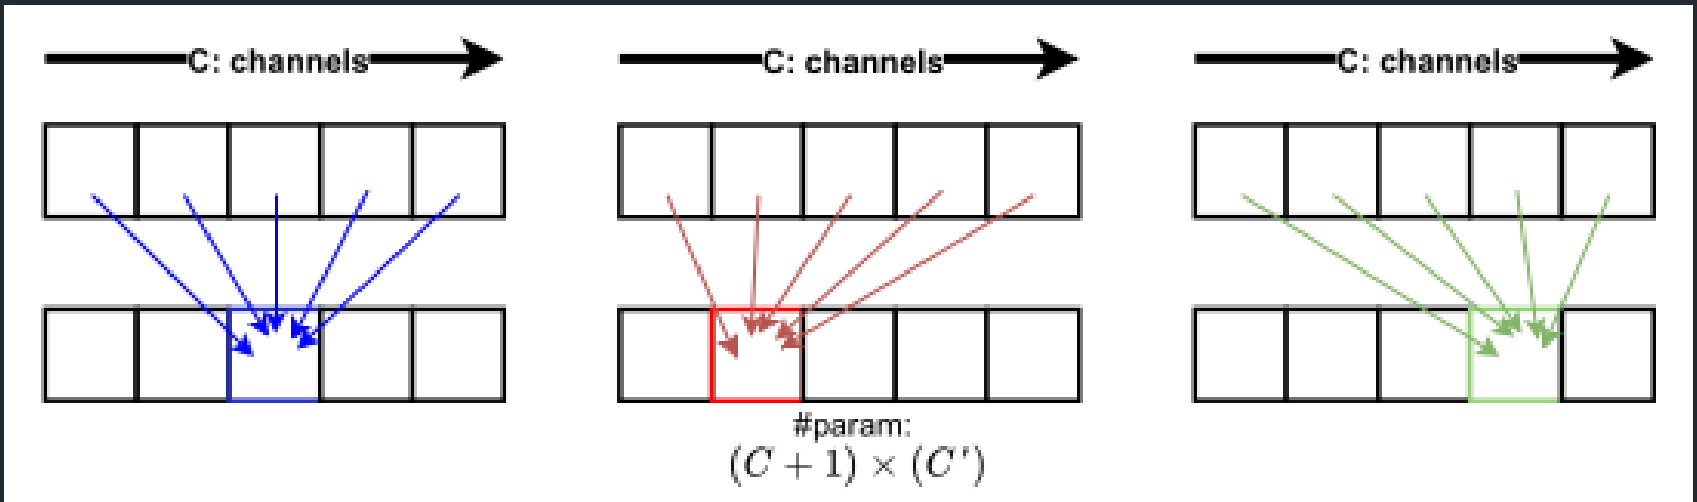

Convolution

- Pour des données image : représentation des données en tenseur (map: $D_{in} \times H \times W \rightarrow D_{out} \times H \times W$
- Passage d'un filtre local pour ne pas connecter tous les pixels
- Apprentissage d'un filtre par channel dans l'image cible : $params = (K \times K \times D_{in} + 1) \times D_{out}$

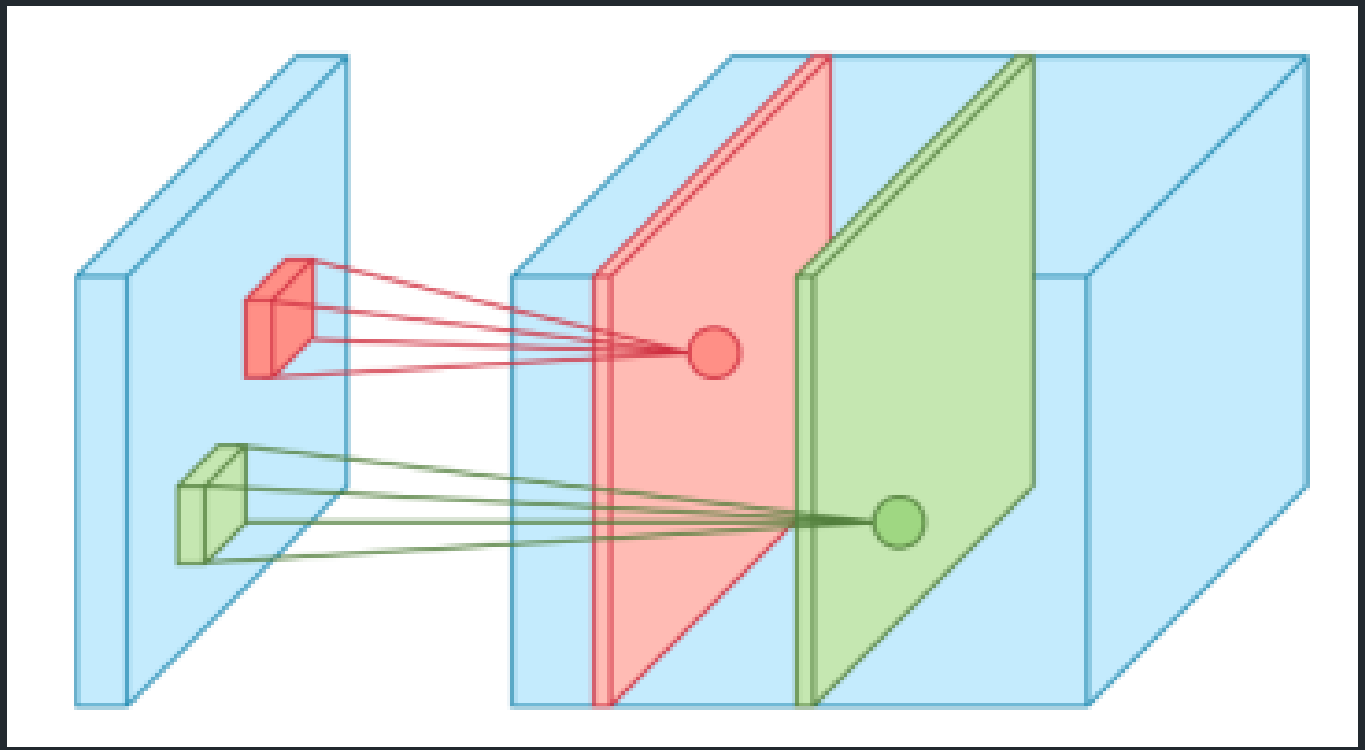

Architecture : Multi-layer Perceptron

Couches linéaires :

$$x_{i+1} = ReLU(Norm(FC_i(x_i)))$$

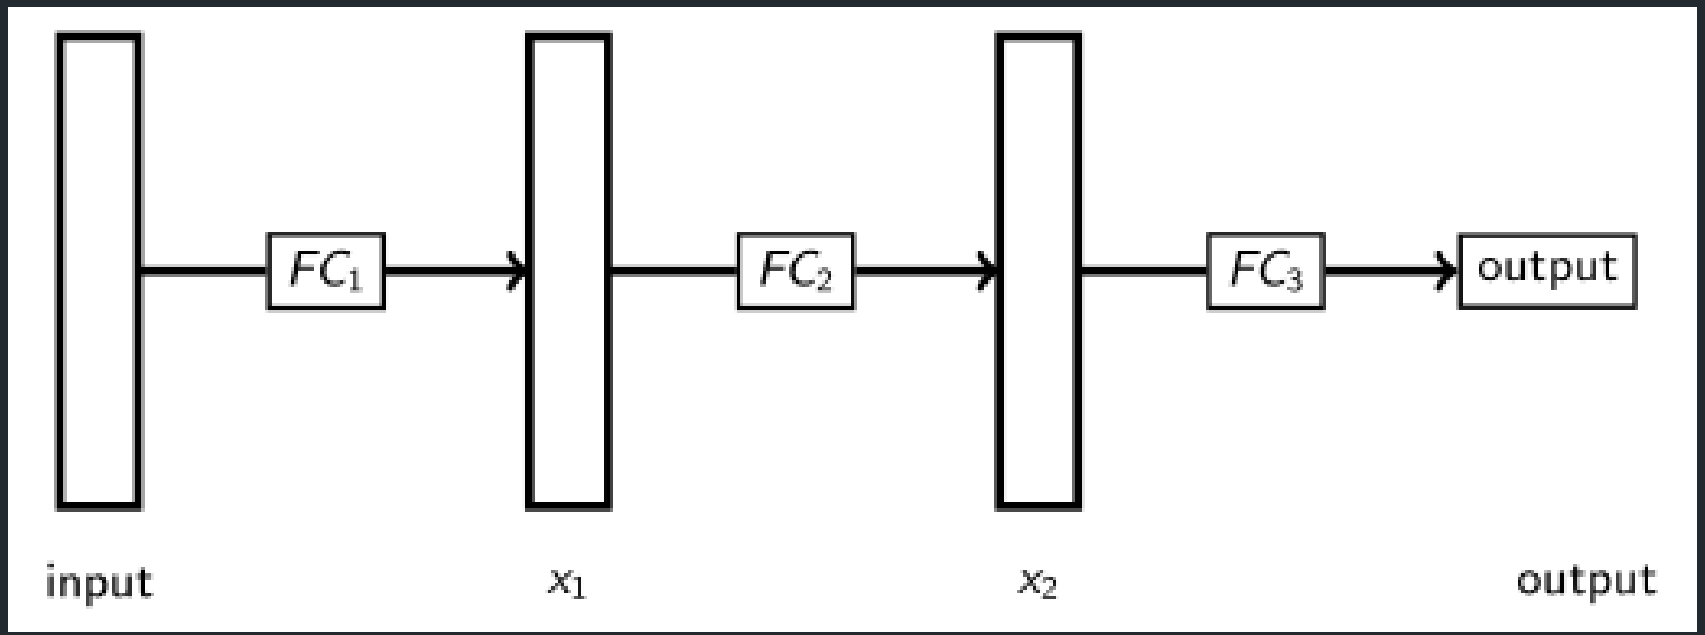

Architecture : Classifieur convolutionnel

- Blocs de convolution : $x_{i+1} = ReLU(Norm(Conv_i(x_i)))$
- Blocs de downsampling
- Blocs de pooling : max ou moyenne sur la dimension spatiale

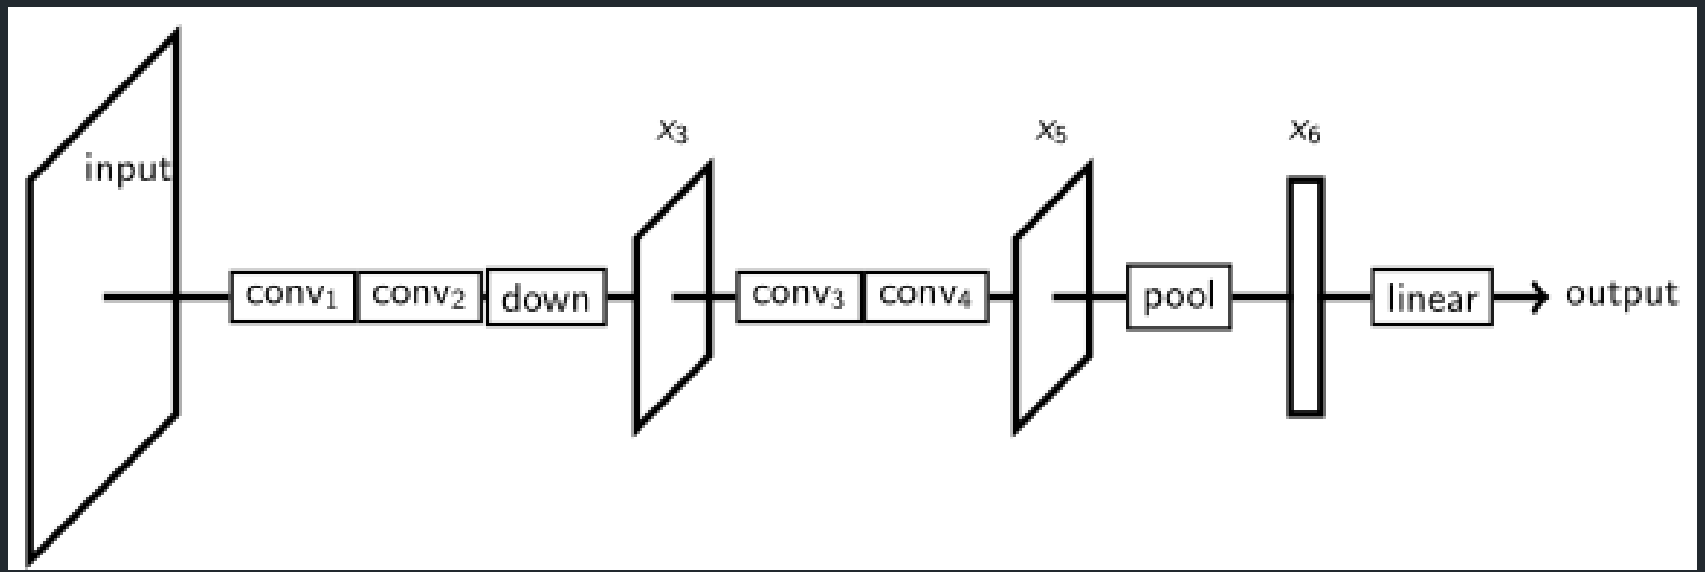

Introduction

Réseaux de Neurones Artificiels

Entraînement

Implémentation

Données raster

Entraînement et Back-propagation

- Fonction de Loss : classique (cross-entropy) ou plus spécifique (ex. Triplet Loss)
- Pour optimiser les poids, descente du gradient de la fonction de Loss
- Algorithme de back-propagation : calcul des couches (forward) gardés en mémoire, puis retour pour le calcul du gradient (dérivée d'une composée)
- **Batch Stochastic Gradient Descent** : gradient le long de samples ("batch") aléatoires (accéléré avec un momentum et un adaptive learning rate)

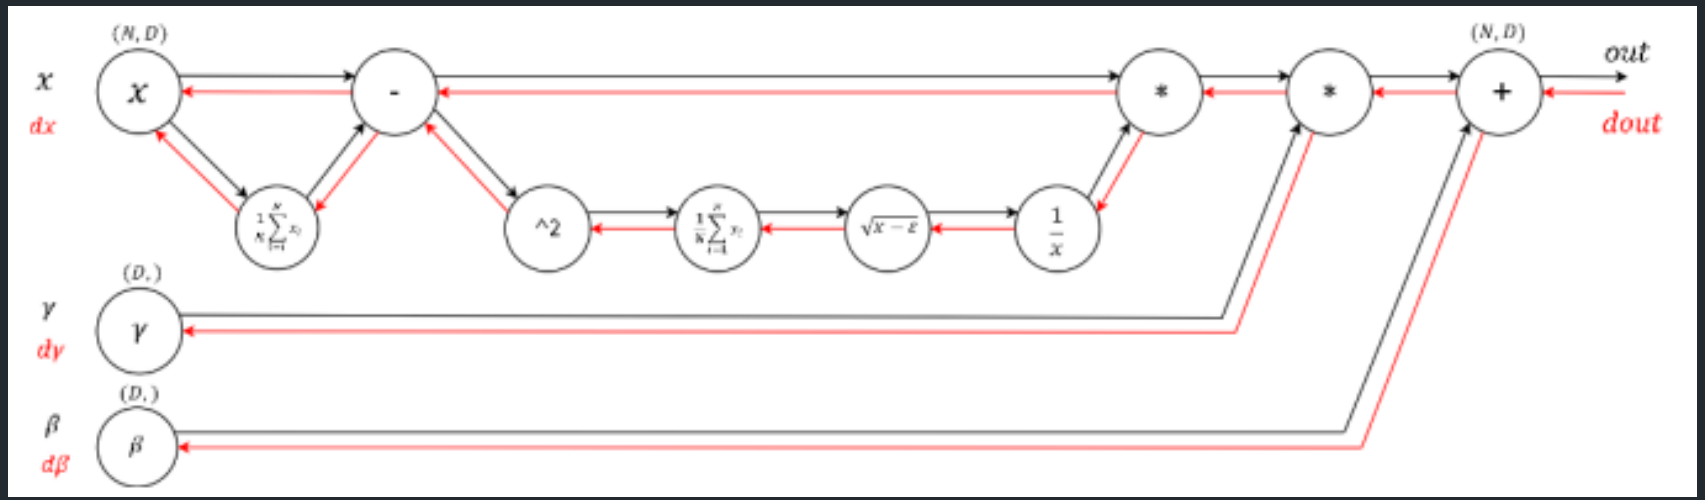

Introduction

Réseaux de Neurones Artificiels

Entraînement

Implémentation

Données raster

Bibliothèques python

ENSG Géomatique

- Packages python pour les architectures, l'optimisation et les calculs GPU: Tensorflow, Pytorch
- Grande banque de couches, architectures, fonctions d'activation, algorithmes d'optimisation, etc.
- Communauté active

Structure du code

- `epoch` : une itération sur le dataset complet
- choix des hyperparamètres, de l'optimisateur
- suivi des performances au fil des itérations

```
model = create_model(options)
optimizer = SGD(model.parameters)
for i_epoch in range(n_epochs):
    perf_train = train_one_epoch(model, optimizer)
    if i_epoch % n_epoch_test == 0:
        perf_test = test(model)
```

Code pour l'entraînement

- `batch` : sample des données, avec `gt` ground truth correspondante
- `criterion` : fonction de Loss
- Evaluation : idem sans calculer le gradient

```
def train_one_epoch(model, optimizer):
    dataset = dataloader(train_set, batch_size = 16)
    metric_meter = empty_meter()
    for batch, gt in dataset:
        model.grad = 0
        pred = model.run(batch)
        loss = criterion(pred, gt)
        loss.backward()
        optimizer.step()
        accuracy = compute_accuracy(pred, gt)
        metric_meter.add(loss, accuracy)
    return metric_meter.values()
```

Code : définition du modèle

Spécification de l'architecture selon des briques prédéfinies

```
def MyModel(nn.Module):
    def __init__(parameters):
        #set up layers
        layer1 = Conv2D(in_channel=3, out_channel=32 ...)
        layer2 = ...
        self.layers = nn.Sequential([layer1, layer2])

    def forward(input):
        #apply model to input
        return self.layers(input)
```

Introduction

Réseaux de Neurones Artificiels

Entraînement

Implémentation

Données raster

Couche de Pooling

Diminue la dimension de l'image

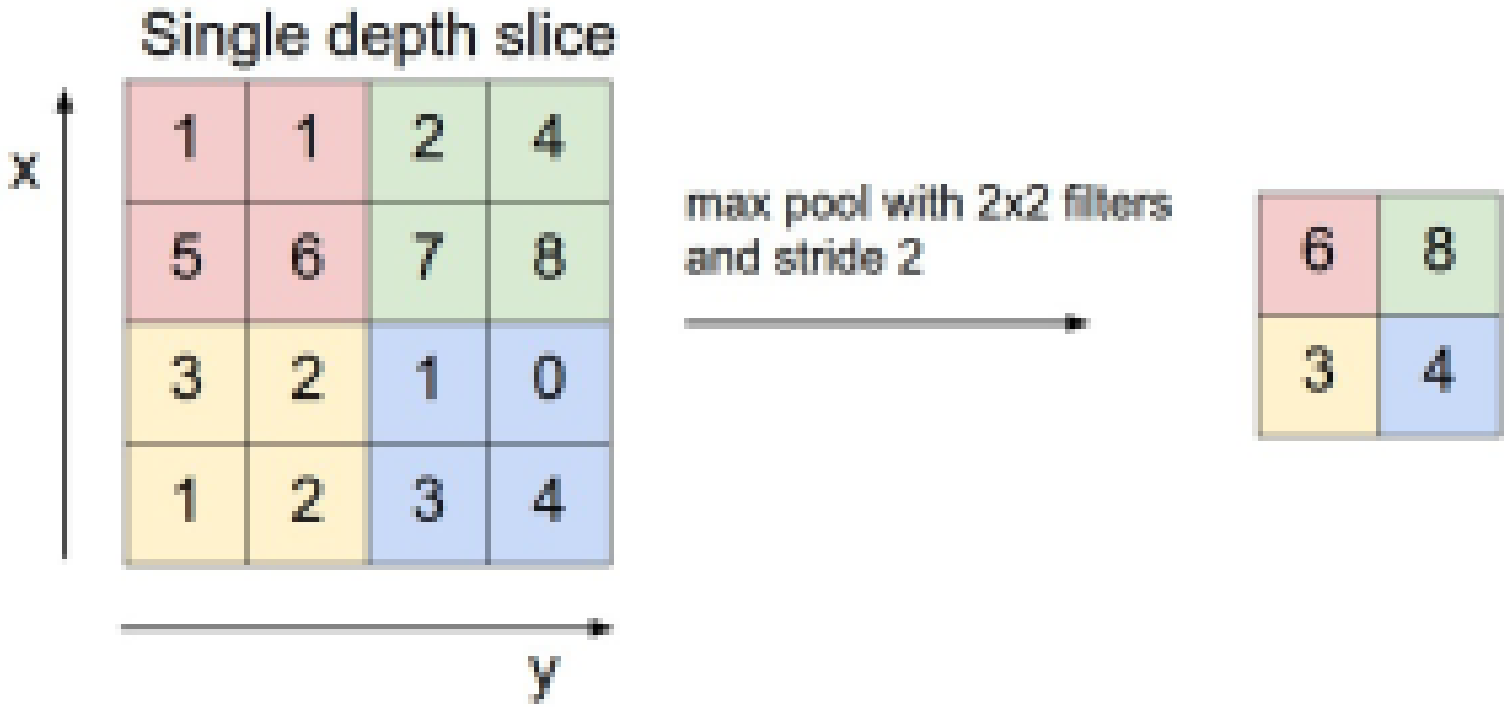

Couche de Un-pooling

Augmente la dimension, à partir d'une carte des indices du pooling

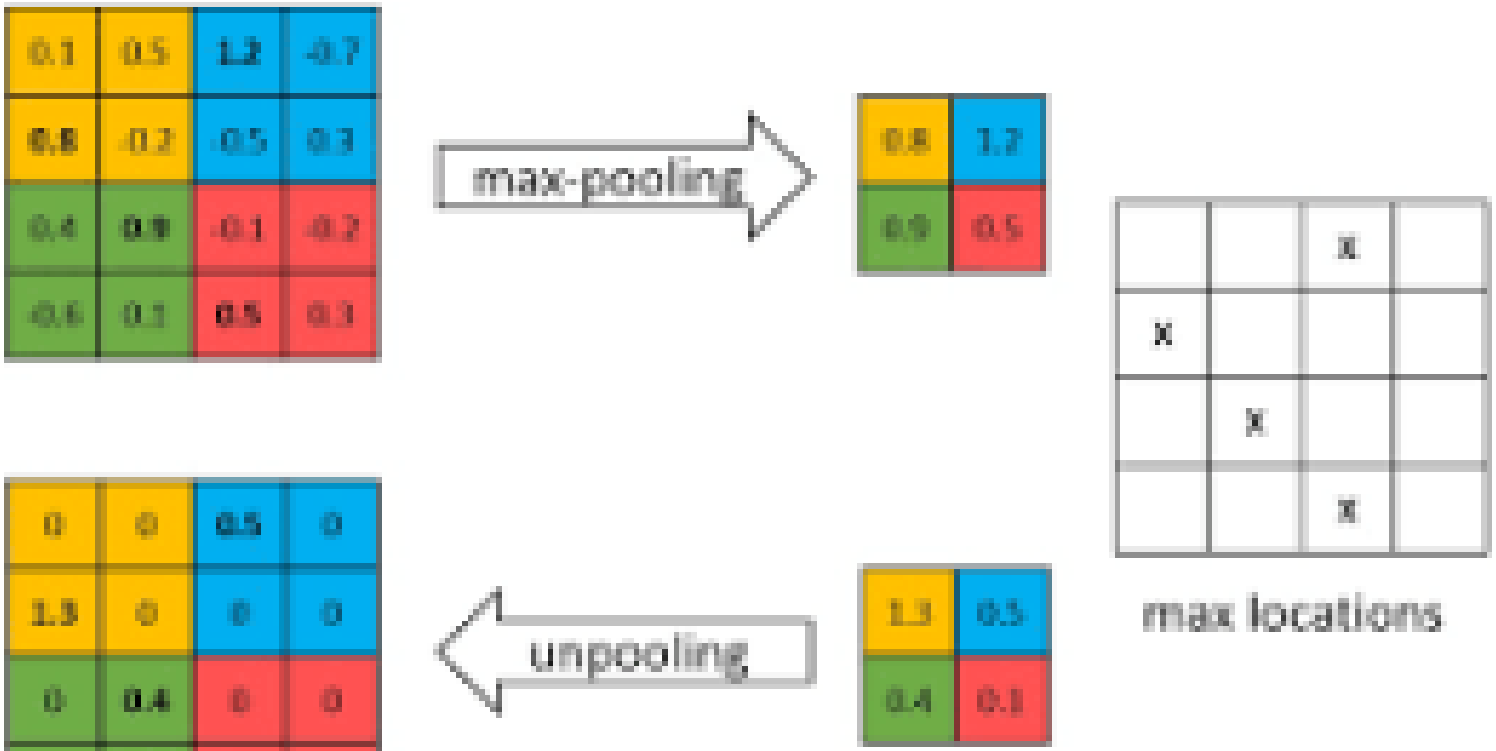

Couche d'attention

- Eteindre les channel les moins importants
- Utilisation d'un Softmax pour simuler une capacité d'attention limitée

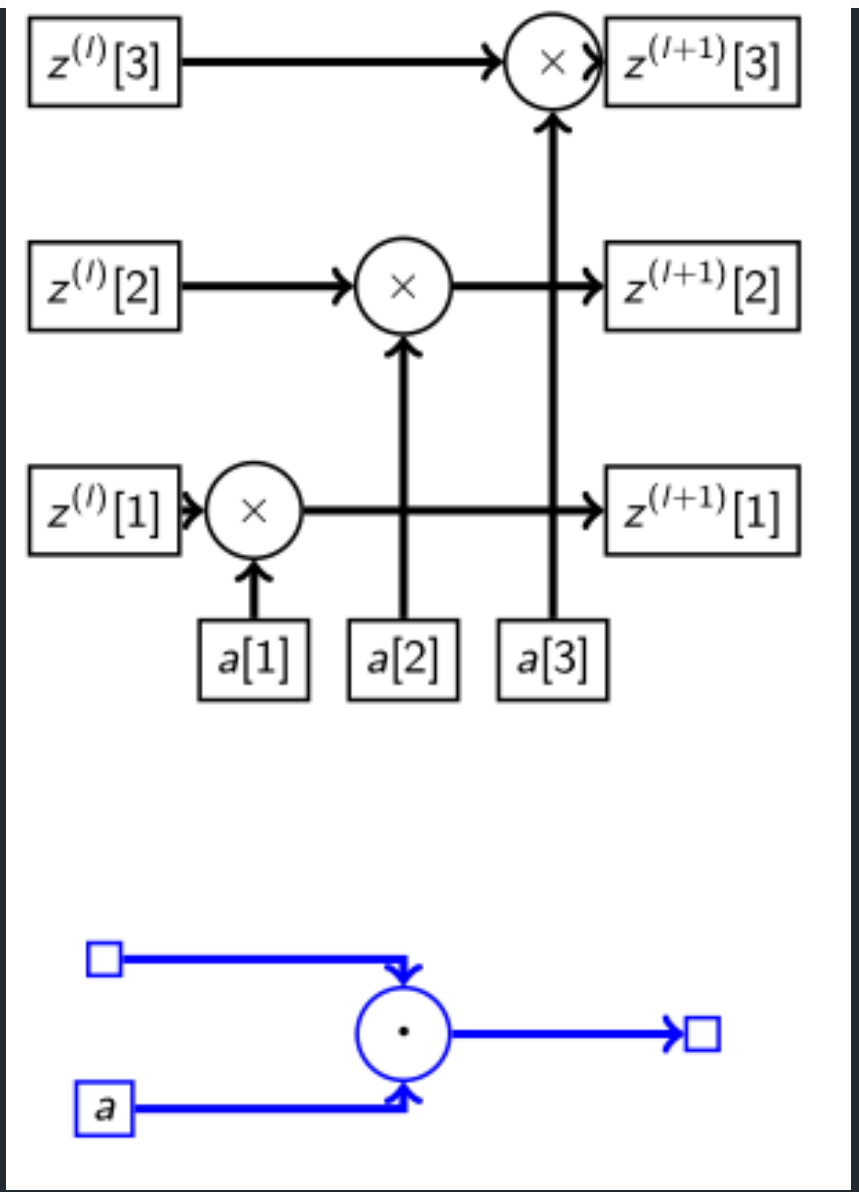

Couches résiduelles

- Problème de la perte d'information exponentielle avec la profondeur du réseau
- Réinjection de l'input pour les réseaux très profonds

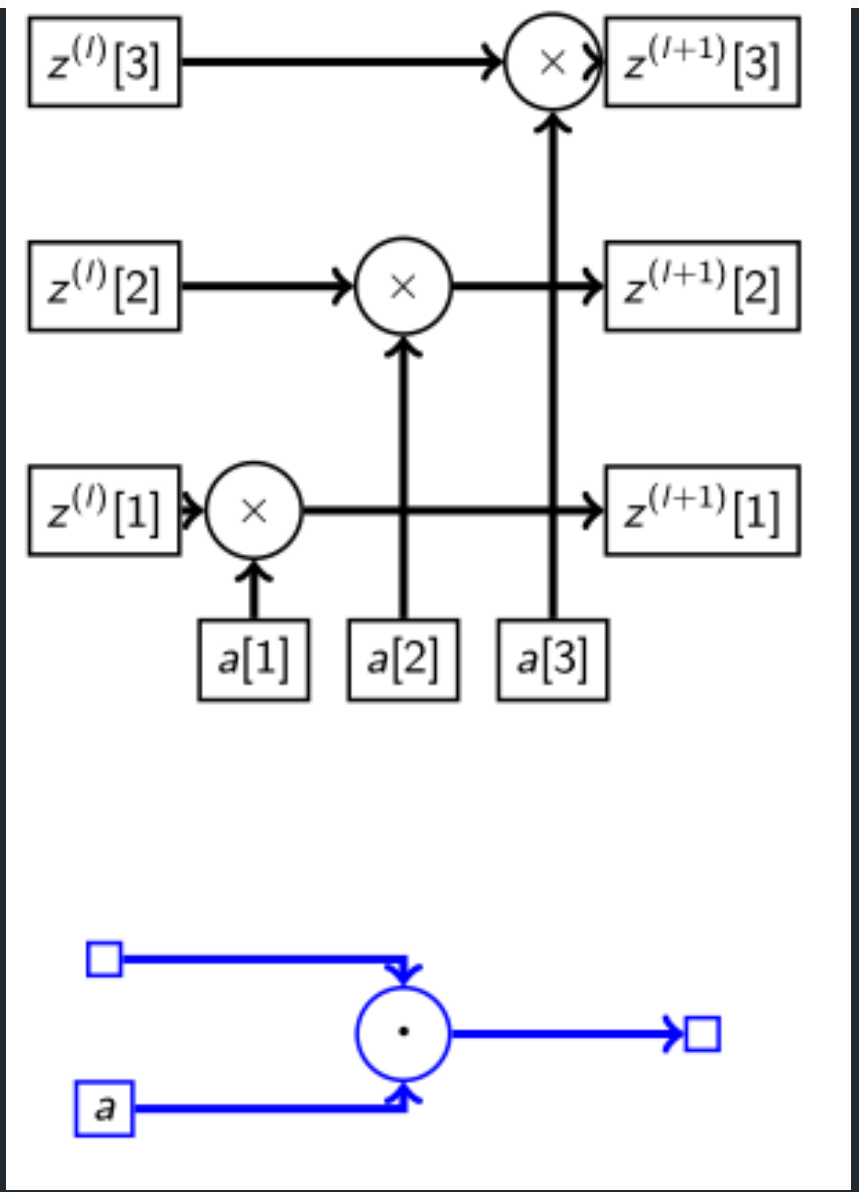

Couches de normalisation

- Limite entre descripteur (encoder) et output (decoder) est floue : besoin d'ajouter des étapes de normalisation dans le réseau
- Selon différentes dimensions : BatchNorm, LayerNorm, InstanceNorm, GroupNorm

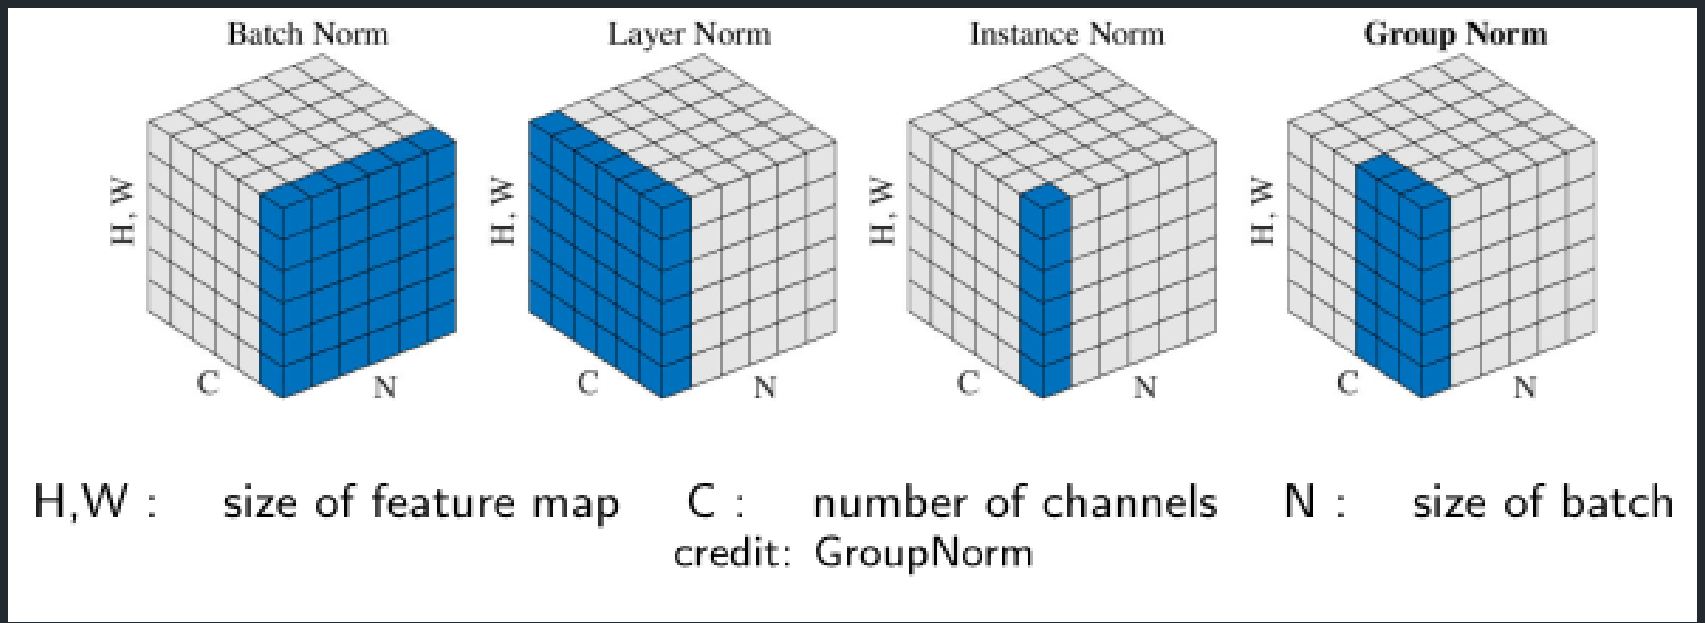

Couche de Dropout

- Régularisation pour diminuer l'overfitting
- Extinction de neurones aléatoires pendant l'entraînement

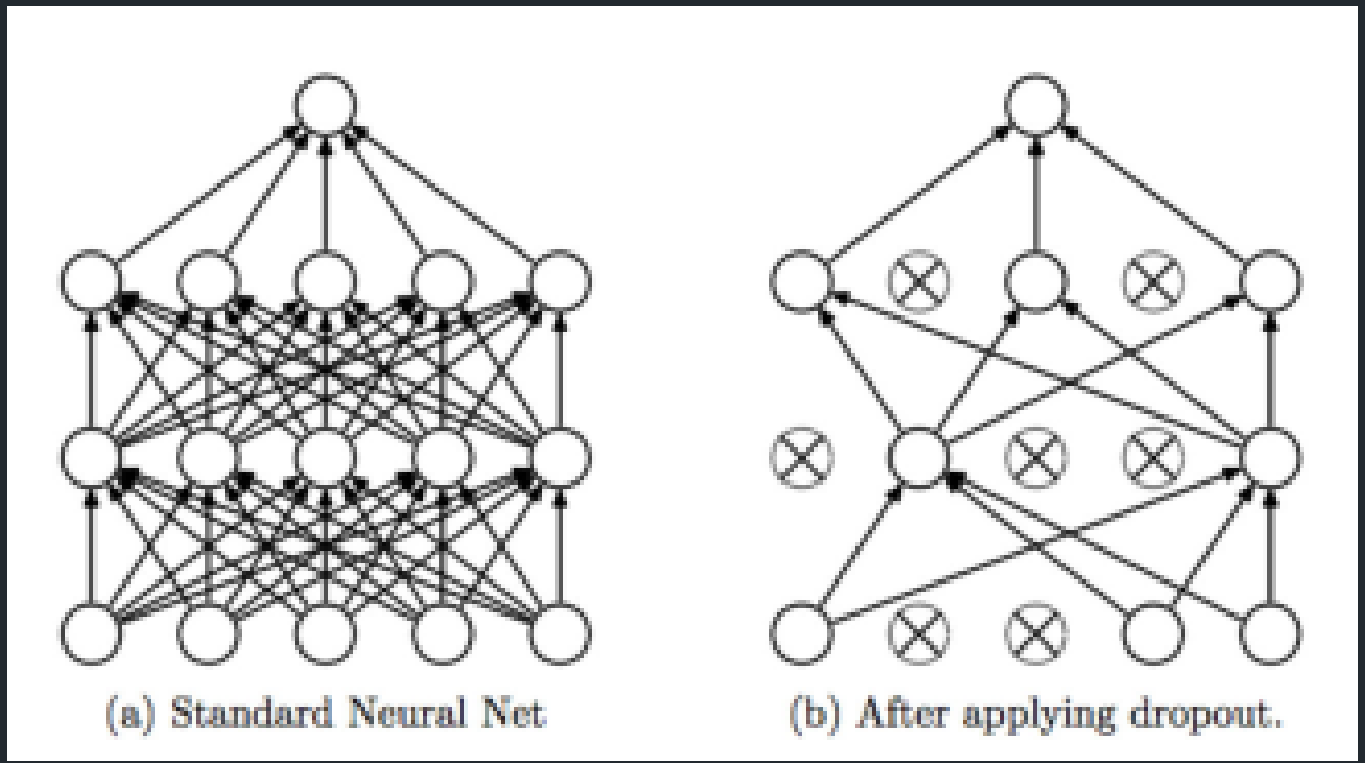

(a) Standard Neural Net

(b) After applying dropout.

Convolutional Encoder-Decoder

Exemple d'architecture pour la segmentation sémantique des images : classification pour chaque pixel

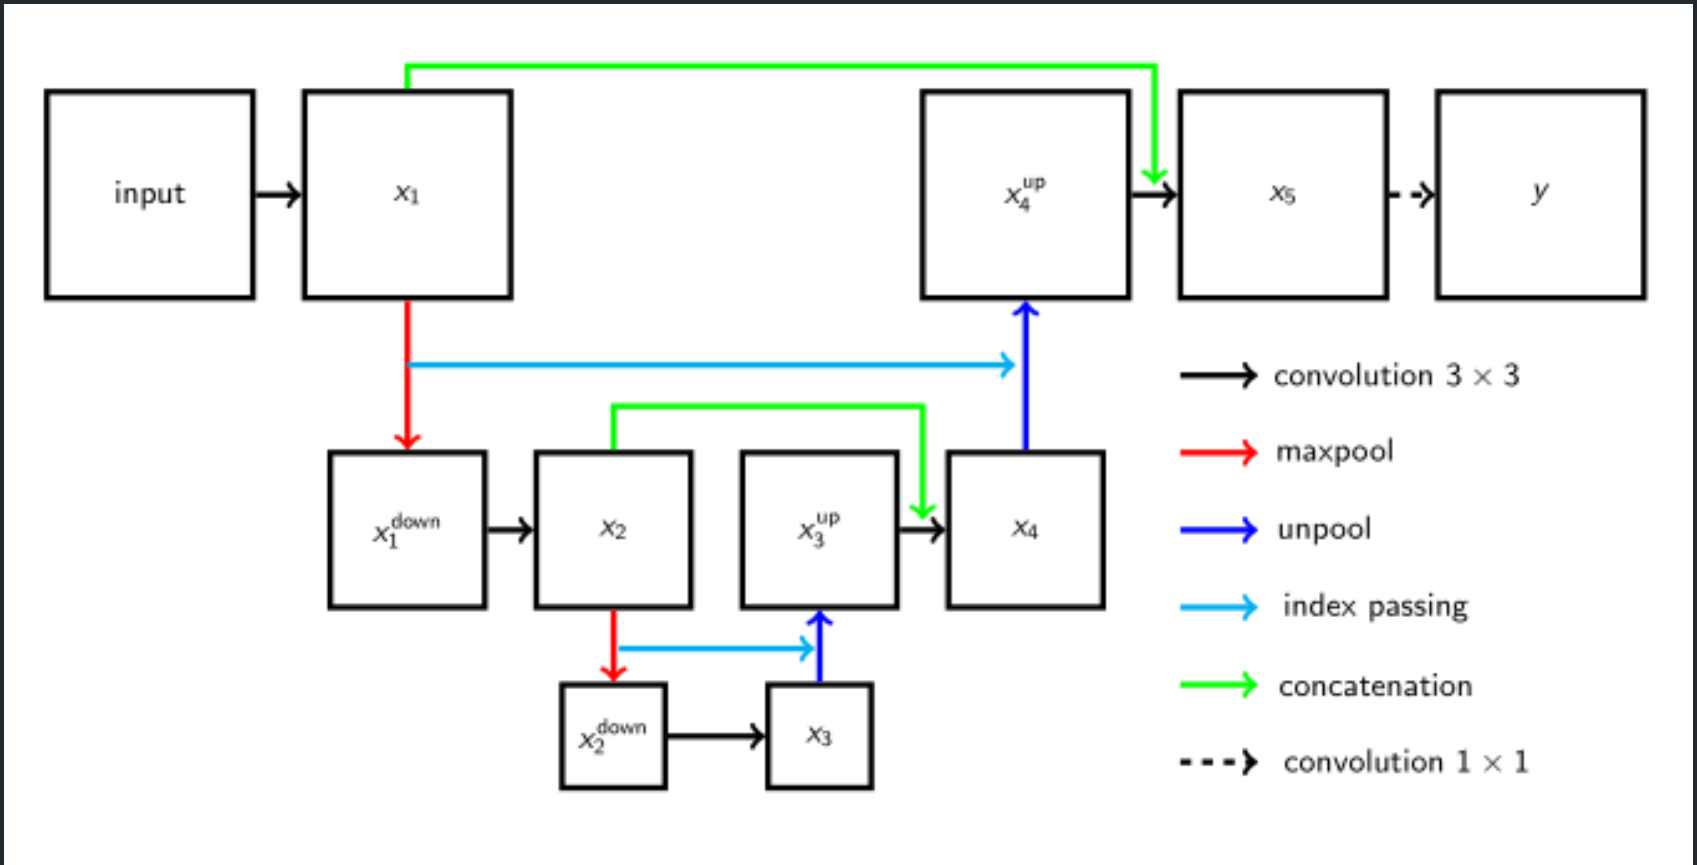

Exemples d'application

Segmentation sémantique de nuages de points 3D dynamiques [Loiseau et al., 2022]

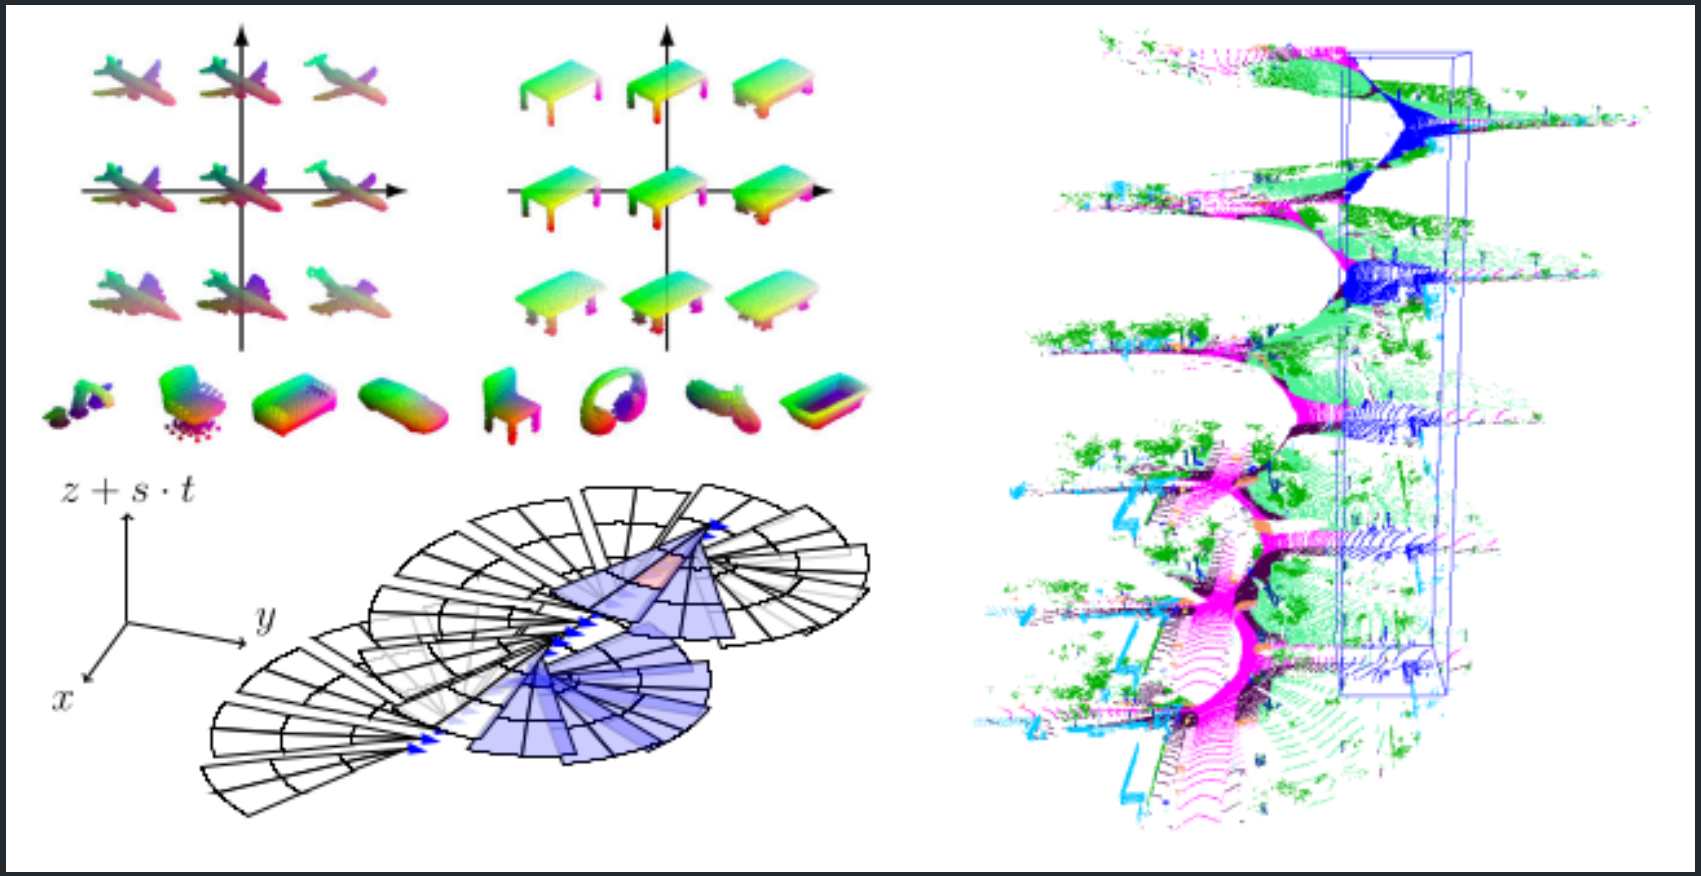

Exemples d'application

Production automatique de cartes d'usage du sol
[Postadjian et al., 2017] (cf données OCS-GE en production)

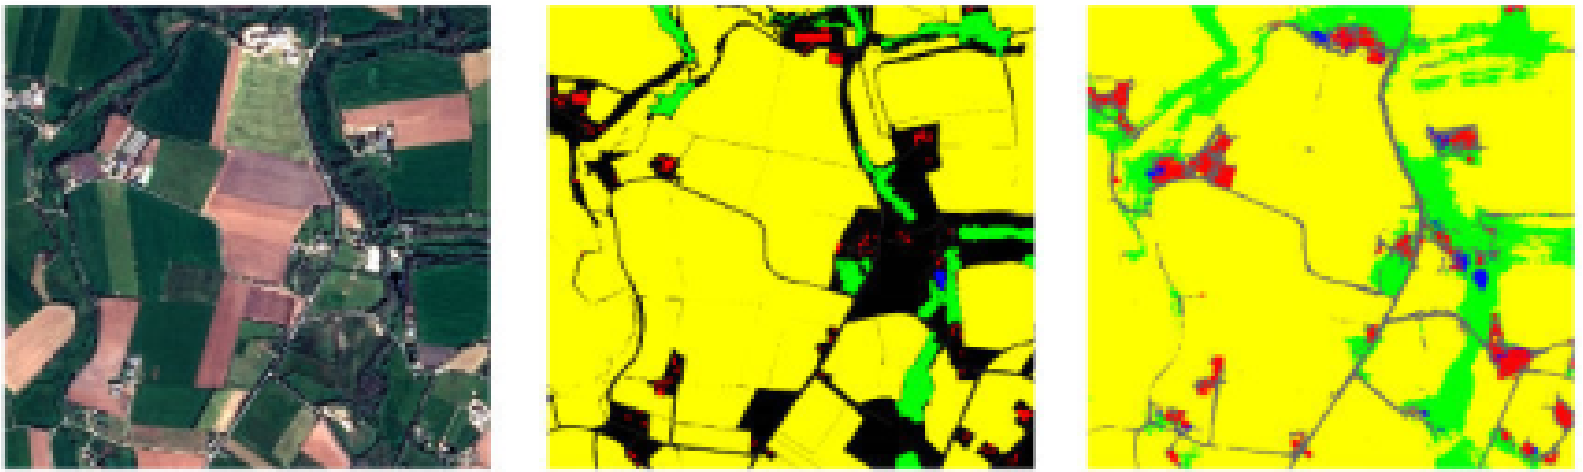

Figure 1. Coverage of the training data. From left to right: Spot 6 image, training data, classification. ● *no training data,* ● *buildings,* ● *roads,* ● *crops,* ● *forest,* ● *water.*

Exemples d'application

Classification de parcelles agricoles à partir de séries temporelles satellite [Garnot et al., 2020]

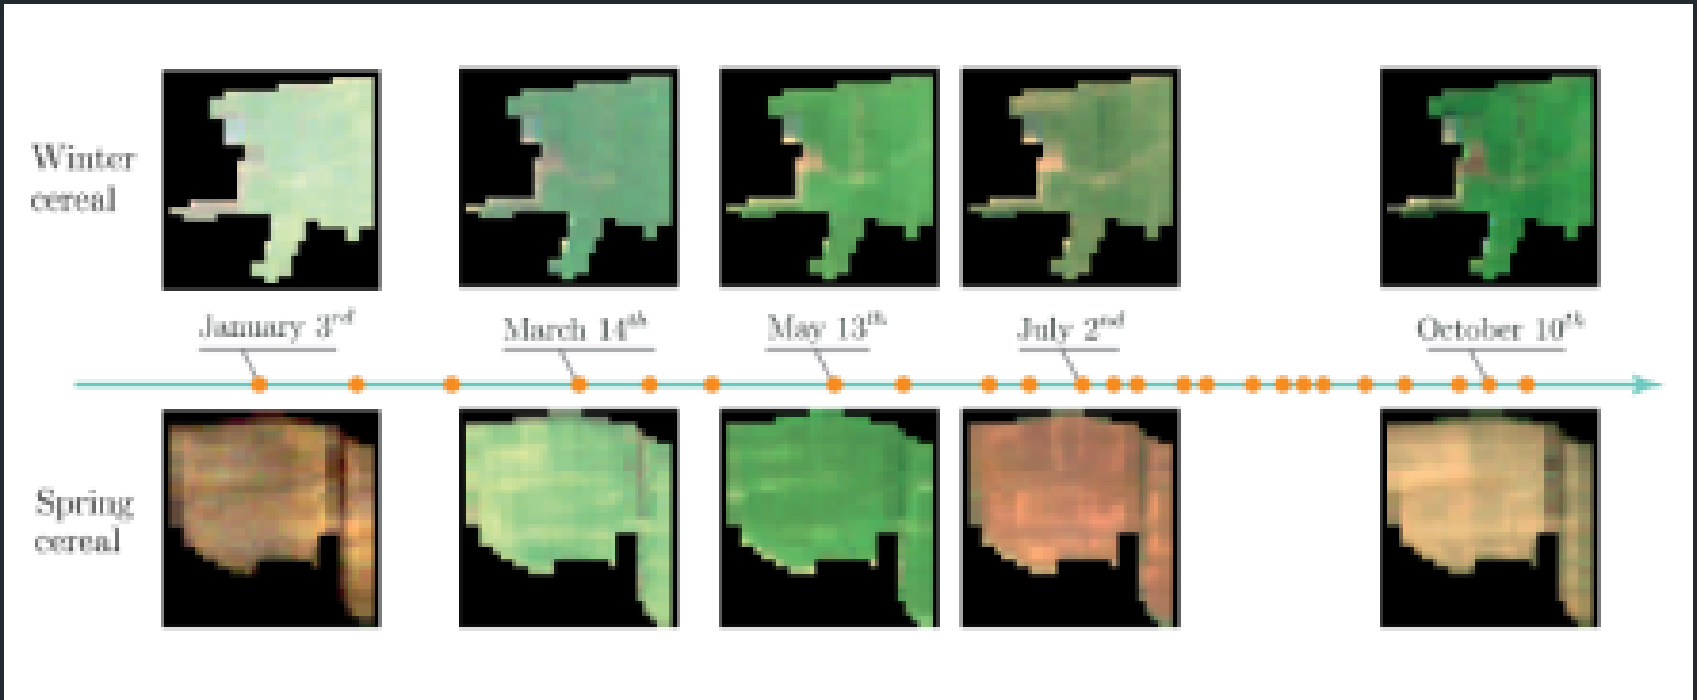

TP

Classification du type de parcelle agricoles dans des données d'image satellite Sentinel-2 [Garnot et al., 2020]

Notebook python sur Google Colab :

`https://colab.research.google.com/drive/1BMX84dvLf6Uwcj8YnG16r9T0f7LKcx0X`

References i

- Cardon, D., Cointet, J.-P., and Mazières, A. (2018).
  La revanche des neurones.
  Réseaux, 211(5):173–220.
- Garnot, V. S. F., Landrieu, L., Giordano, S., and Chehata, N. (2020).
  Satellite image time series classification with pixel-set encoders and temporal self-attention.
  In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 12325–12334.

References ii

- Loiseau, R., Aubry, M., and Landrieu, L. (2022). **Online segmentation of lidar sequences: Dataset and algorithm.** In *European Conference on Computer Vision*, pages 301–317. Springer.
- Postadjian, T., Le Bris, A., Sahbi, H., and Mallet, C. (2017). **Investigating the potential of deep neural networks for large-scale classification of very high resolution satellite images.** *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 4:183–190.